



1 INTRODUCCIÓN

Los **modelos de lenguaje de gran escala (LLMs, del inglés *Large Language Models*)** han irrumpido como herramientas transformadoras en la ciencia. Su capacidad de razonamiento y de procesar **lenguaje natural** permite abordar, mediante simples instrucciones conversacionales, tareas que antes exigían *software* especializado o programación avanzada.

En **química analítica**, la interpretación de datos espectroscópicos normalmente se apoya en el **análisis multivariante**: análisis de componentes principales (PCA), análisis discriminante por mínimos cuadrados parciales (PLS-DA), máquinas de vectores soporte (SVM) y *Random Forest* (RF), que requiere dominio de *R*, *MATLAB* o *Python*. Los LLMs prometen **democratizar el análisis quimiométrico**; pero la fluidez lingüística no garantiza competencia analítica.


Este trabajo evalúa de forma **sistemática y comparativa** cinco LLMs de última generación sobre datos reales de **RMN-¹H de aceites vegetales**.

OBJETIVO

Evaluar la capacidad de **5 LLMs de última generación** para ejecutar un **flujo de trabajo quimiométrico completo** sobre datos reales, contrastándolos con el *software* de referencia **SIMCA** (Umetrics).

3 FLUJO DE TRABAJO

Cada modelo recibió la **misma secuencia estandarizada** de instrucciones en lenguaje natural: carga y auditoría, pretratamiento espectral, PCA, agrupamiento *K-means*, clasificación supervisada (PLS-DA; SVM; RF), validación, interpretabilidad y autoevaluación, comparándolas con el **flujo quimiométrico convencional**:




Flujo conversacional con los 5 LLMs frente al enfoque convencional (SIMCA, Umetrics)

2 MUESTRAS Y DATOS

Conjunto de **resonancia magnética nuclear de protón de campo bajo** (RMN-¹H; espectrómetro de sobremesa Nanalysis 100 MHz) de tres aceites vegetales comestibles. Las **9 muestras incógnita**, excluidas del entrenamiento, evaluaron la capacidad real de predicción de cada modelo.

66 muestras (22/tipo) = 57 etiquetadas + 9 incógnita



Espectros RMN-¹H representativos: **AOVE** (oliva virgen extra), **AG** (girasol) y **AGAO** (girasol alto oleico).


4 MODELOS EVALUADOS

Claude Opus 4.6	Anthropic Empresa privada · Razonamiento avanzado y alta direccionabilidad	Arena 1504
Gemini 3.1 Pro	Google DeepMind Empresa privada · Multimodal · integración con Google	Arena 1493
Grok-4	xAI Empresa privada · Información en tiempo real (plataforma X)	Arena 1491
ChatGPT 5.6	OpenAI Empresa privada · Multimodal (texto, imagen, audio) · contexto amplio	Arena 1484
Qwen 3.5	Alibaba Cloud Código abierto · Despliegue local · pesos abiertos	Arena 1465

Arena Score: ranking público de LLMs por preferencia de usuarios (Chatbot Arena, Imarena.ai); orden de mayor a menor

5 RESULTADOS

Los resultados revelan una **jerarquía de rendimiento clara** entre los modelos evaluados, validada sobre los mismos datos de RMN-¹H:



PCA — A) SIMCA (ref.) · B) Claude · C) Gemini · D) Grok · E) ChatGPT · F) Qwen

CLAUDE OPUS 4.6

El modelo más autónomo y riguroso; pretratamiento de 6 pasos justificado; validación con permutaciones ($p < 0,002$). Acertó las 9 incógnitas.

GEMINI · ChatGPT

Rendimiento excelente: 100 % de acierto en la clasificación, predicción correcta de todas las incógnitas e interpretación químicamente coherente.

GROK-4

Resultados próximos al 100 %, con menor profundidad exploratoria y autonomía en el manejo de datos.

QWEN 3.5

Único de código abierto: error interno irrecuperable en la clasificación supervisada (>20 min de intentos).

Criterio de evaluación	Referencia (SIMCA) Umetrics	Claude Opus 4.6 Arena 1504	Gemini 3.1 Pro Arena 1493	Grok-4 Arena 1491	ChatGPT 5.6 Arena 1484	Qwen 3.5 Arena 1465
Manejo de datos	++	+++	+	+	+++	++
Pretratamiento espectral	+++	+++	++	+++	++	+
Análisis exploratorio (PCA)	++	+++	++	++	+++	+
Análisis no supervisado	+++	+++	+++	++	+++	+
Análisis supervisado	+++	+++	+++	++	+++	—
Validación de modelos	++	+++	++	++	+++	—
Interpretabilidad	+	+++	++	++	++	—
Autoevaluación crítica	—	+++	+++	++	+++	—
Eficiencia	—	+++	+	+	+++	++
PUNTUACIÓN GLOBAL	Adecuado	Sobresaliente	Excelente	Bueno	Excelente	No fiable

Matriz de evaluación · +++ muy alto · ++ alto · + aceptable · — nulo

6 CONCLUSIONES

Los LLMs líderes **igualan funcionalmente al software quimiométrico especializado**; Claude Opus 4.6 es el más completo y autónomo.

La **fluidez lingüística no garantiza competencia analítica**; los *benchmarks* generalistas pueden no reflejar el rendimiento quimiométrico.

La **supervisión humana sigue siendo indispensable** para un despliegue fiable en flujos espectroscópicos.

Los LLMs son **co-pilotos analíticos competentes**, no sustitutos del criterio experto.